Projeto de Data Science: Dengue no Brasil – Clima, Sazonalidade e Previsão de Casos

Documentação base de um projeto de análise de **dados abertos de saúde** com Python, desenhado para produzir uma análise real, reprodutível e cientificamente defensável.

1. Resumo e pergunta central

Pergunta principal: variáveis climáticas defasadas (temperatura, precipitação, umidade) **melhoram a previsão de curto prazo (1 a 8 semanas) da incidência de dengue** em uma UF ou município, em comparação com modelos que usam apenas o histórico de casos?

Entregável: um repositório com pipeline completo (ingestão, qualidade, análise exploratória, modelagem, validação temporal, interpretação) e um relatório final, em que **cada conclusão pode ser reproduzida com um comando**.

2. Por que este projeto

- **Problema real e relevante:** a dengue é uma doença de notificação compulsória e de grande impacto no sistema de saúde brasileiro.
- **Dados oficiais, abertos e anonimizados:** notificações individuais do SINAN, com séries longas e cobertura nacional.
- **Desafios autênticos de ciência de dados:** sazonalidade forte, anos epidêmicos raros, atraso de notificação, subnotificação, mudanças de definição de caso e dados espaciais.
- **Permite demonstrar rigor:** baselines honestos, validação temporal, incerteza quantificada e discussão de vieses.
- **Cobre o ciclo completo:** engenharia de dados, estatística, machine learning, geoprocessamento e comunicação.

3. Fontes de dados

Fonte	Conteúdo	Acesso	Observações
SINAN – Dengue (DATASUS)	Notificações individuais anonimizadas: datas de notificação e de primeiros sintomas, município, classificação final, critério de confirmação, idade, sexo	Plataforma de dados abertos do DATASUS, FTP do DATASUS ou biblioteca **PySUS**	Confirmar anos disponíveis, formato e dicionário de dados atual (pasta `Docs_TAB_SINAN`)
TABNET / IVIS (DATASUS)	Dados consolidados do SINAN	Web	Usar para **conferir** a contagem do seu pipeline
INMET	Séries meteorológicas históricas de estações (temperatura, precipitação, umidade)	Portal de dados históricos do INMET	Lacunas e estações descontinuadas; exige mapeamento estação → município
IBGE	População estimada, códigos e malha municipal	Portal do IBGE ou PySUS	Denominador para incidência por 100 mil habitantes
InfoDengue (opcional)	Estimativas e nowcasting de casos (Fiocruz/FGV)	API pública	Usar como **benchmark externo**, não como verdade
ERA5 (Copernicus) (opcional)	Clima em grade	Copernicus CDS	Alternativa para municípios sem estação próxima

> **Importante:** disponibilidade, anos cobertos e formatos mudam com o tempo. Na Fase 0, registre **data, versão e hash** de cada arquivo baixado, e confirme os códigos das variáveis no dicionário de dados oficial antes de usá-los.

4. Perguntas e hipóteses

ID	Pergunta	Tipo
P1	Clima defasado reduz o erro de previsão frente a baselines sazonais e autorregressivos?	Preditiva (principal)
P2	Quais defasagens (em semanas) de temperatura e chuva mais se associam à incidência?	Exploratória
P3	Existem grupos de municípios com perfis sazonais semelhantes?	Descritiva (clustering)
P4	Há autocorrelação espacial da incidência entre municípios vizinhos?	Espacial
P5 (opcional)	Que características das notificações se associam a formas graves (sinais de alarme ou dengue grave)?	Associativa, com cautela

Hipóteses falsificáveis:

- **H1:** adicionar temperatura e precipitação defasadas reduz o MAE em relação ao melhor baseline em pelo menos uma parte dos horizontes avaliados.
- **H2:** o ganho varia por região e por tamanho do município.
- **H3:** tratar o atraso de notificação melhora a previsão nas semanas mais recentes.

Cada hipótese deve ter critério de decisão escrito **antes** da análise final (ver REG-07).

5. Plano analítico

5.1 Ingestão e versionamento

Baixar os dados por script (nunca manualmente), salvar em formato colunar (Parquet) e registrar origem, data e hash.

5.2 Qualidade e definição de caso

- **Caso provável:** notificação **não descartada** (confirmar o código de `CLASSI_FIN` no dicionário).
- **Data de referência: primeiros sintomas** (`DT_SIN_PRI`), e não a data de notificação, para refletir a dinâmica da doença.
- **Agregação:** semana epidemiológica (SE) por município e por UF.

- **Limpeza:** duplicidades, datas impossíveis, códigos de município inválidos, idades fora da faixa.
- **Funil de exclusão:** registrar quantos registros foram removidos em cada etapa e por quê.

5.3 Análise exploratória

Série temporal e sazonalidade, anos epidêmicos, mapas de incidência, padrão de dados faltantes, **distribuição do atraso** (notificação menos primeiros sintomas) e comparação com o TABNET.

5.4 Engenharia de atributos

- Incidência por 100 mil habitantes.
- Defasagens de casos (1 a 8 semanas) e médias móveis.
- Defasagens e médias móveis climáticas (temperatura, chuva, umidade) até 12 semanas.
- Sazonalidade (seno e cosseno da SE) e tendência.
- Regra de ouro: **só informação disponível no momento da previsão**.

5.5 Modelagem (do mais simples ao mais complexo)

Nível	Modelo	Papel
Baseline 1	Seasonal naive (mesma SE do ano anterior)	Piso de desempenho
Baseline 2	Persistência (último valor conhecido)	Piso de curto prazo
Estatístico	Regressão Poisson ou Binomial Negativa com defasagens (`statsmodels`)	Interpretável, com intervalos
Estatístico	SARIMAX ou ETS	Referência clássica de séries
ML	Gradient boosting (LightGBM) com perda quantílica	Não linear, gera intervalos
Opcional	GAM (`pygam`) ou modelo bayesiano hierárquico (PyMC)	Efeitos não lineares e espaciais

5.6 Validação

Validação **rolling-origin** (janela expansiva): treinar no passado, prever o futuro, avançar o corte e repetir. Nunca usar k-fold aleatório. Reservar um **conjunto de teste final** (por exemplo, os dois anos mais recentes) aberto uma única vez.

5.7 Interpretação e robustez

Resíduos por período e por região, erro em semanas de pico (magnitude e antecedência), importância de atributos (SHAP ou coeficientes), curvas defasagem–resposta, sensibilidade a escolhas de limpeza e comparação com o InfoDengue.

5.8 Comunicação

Relatório em Quarto (ou Jupyter Book) com pergunta, métodos, resultados, **limitações** e conclusões proporcionais à evidência.

6. Regras de rigor científico (obrigatórias)

ID	Regra	Verificação
REG-01	**Sem vazamento temporal:** toda feature do instante t usa apenas informação disponível até t; splits sempre cronológicos	Teste automatizado
REG-02	Validação **rolling-origin**; proibido k-fold aleatório em série temporal	Revisão de código
REG-03	Todo modelo é comparado a pelo menos dois baselines; ganhos reportados com intervalo de confiança (bootstrap em blocos)	Relatório
REG-04	Reportar **incerteza**: intervalos de previsão e cobertura empírica (80% e 95%)	Relatório
REG-05	Comparações entre locais usam **incidência por população**, não contagem bruta	Revisão
REG-06	Tratar ou declarar o **atraso de notificação**; semanas recentes incompletas são sinalizadas	Relatório
REG-07	**Plano de análise registrado** (hipóteses, métricas, janelas) antes de olhar o teste final; teste final aberto uma única vez	Commit do plano com data
REG-08	**Reprodutibilidade:** ambiente travado, seeds fixas, dados versionados por hash, pipeline roda de ponta a ponta com um comando	CI
REG-09	**Contratos de dados** validados (colunas, tipos, domínios, datas plausíveis) com `pandera` ou Great Expectations	Testes

ID	Regra	Verificação
REG-10	Notebooks para exploração e narrativa; **lógica em módulos testados** (`pytest`)	Revisão
REG-11	Linguagem causal proibida sem desenho causal: usar "associado a", não "causa"	Revisão
REG-12	Toda decisão de limpeza documentada com contagem de registros afetados	Funil de exclusão
REG-13	Resultados negativos ou ganhos pequenos são reportados como tal	Relatório
REG-14	Pré-processamentos que aprendem parâmetros (escalonamento, imputação) são ajustados **só no treino** de cada dobra	Teste

7. Stack sugerida

Área	Ferramentas
Ingestão	`pysus` , `requests`
Dados	`pandas` ou `polars` , `pyarrow` (Parquet), `duckdb`
Geoprocessamento	`geopandas` , `shapely` , `libpysal` e `esda` (Moran), `folium` ou `plotly`
Estatística	`statsmodels` , `scipy` , `pygam`
Machine learning	`scikit-learn` , `lightgbm` , `shap`
Séries temporais	`statsforecast` ou `sktime` (opcional), `epiweeks`
Bayesiano (opcional)	`pymc` , `arviz`
Validação de dados	`pandera`
Visualização	`matplotlib` , `seaborn` , `plotly`
Reprodutibilidade	`uv` ou `poetry` , DVC (ou Make), `pre-commit` , `ruff` , `pytest`
Relatório	Quarto ou Jupyter Book
Rastreio de experimentos (opcional)	MLflow

8. Estrutura do repositório

```
dengue-clima/
├── README.md
├── pyproject.toml              # dependências travadas
├── Makefile                    # make data | features | train | report |
test
├── docs/
|   ├── plano_de_analise.md     # hipóteses e critérios (REG-07)
|   ├── dicionario_de_dados.md
|   └── decisoes/               # registros de decisão (ADRs)
├── data/
|   ├── raw/                    # nunca editado; versionado por hash
|   ├── interim/
|   └── processed/
├── src/dengue/
|   ├── ingestao/               # SINAN, INMET, IBGE
|   ├── qualidade/              # contratos e limpeza
|   ├── features/               # lags, sazonalidade, clima
|   ├── modelos/                # baselines, GLM, LightGBM
|   ├── validacao/              # rolling-origin, métricas
|   └── visualizacao/
├── notebooks/                  # exploração e narrativa
├── tests/                      # unitários, contratos, anti-vazamento
└── reports/                    # relatório Quarto e figuras
```

9. Esqueletos de código de referência

> A API do PySUS mudou entre versões; confira a documentação da versão instalada. Códigos e tipos das colunas devem ser confirmados no dicionário de dados.

9.1 Ingestão e agregação semanal

```
import pandas as pd
from pysus.api import sinan

bruto = sinan(disease="deng", year=[2022, 2023, 2024])

notificacoes = (
    bruto.assign(
        dt_sintomas=lambda d: pd.to_datetime(d["DT_SIN_PRI"],
errors="coerce"),
        municipio=lambda d: d["ID_MUNICIP"].astype(str),
```

```
    )
    .loc[lambda d: d["CLASSI_FIN"].astype(str) != "5"]   # exclui descartados
(confirmar código)
    .dropna(subset=["dt_sintomas"])
)

# Semana começando no domingo (aproximação; para a SE oficial use a
biblioteca epiweeks)
notificacoes["semana"] = notificacoes["dt_sintomas"].dt.to_period("W-
SAT").dt.start_time

casos = (
    notificacoes.groupby(["municipio",
"semana"]).size().rename("casos").reset_index()
)
```

9.2 Atributos defasados sem vazamento

```
def adicionar_defasagens(painel: pd.DataFrame, colunas, defasagens) ->
pd.DataFrame:
    painel = painel.sort_values(["municipio", "semana"]).copy()
    for col in colunas:
        for k in defasagens:
            painel[f"{col}_lag{k}"] = painel.groupby("municipio")
[col].shift(k)  # k > 0 = passado
    return painel

# Para prever com horizonte h, use apenas defasagens k >= h:
HORIZONTE = 4
painel = adicionar_defasagens(painel, ["casos", "temp_media", "chuva_acum"],
range(HORIZONTE, 13))
```

9.3 Validação rolling-origin

```
def rolling_origin(painel, inicio_teste, horizonte=4, passo=1):
    semanas = sorted(painel["semana"].unique())
    cortes = semanas[semanas.index(inicio_teste)::passo]
    for corte in cortes:
        # rótulos conhecidos no momento da previsão: até corte - horizonte
        treino = painel[painel["semana"] <= corte -
pd.Timedelta(weeks=horizonte)]
        teste = painel[painel["semana"] == corte]
        yield treino, teste
```

9.4 Teste anti-vazamento (REG-01)

```
def test_features_respeitam_horizonte(colunas_de_features):
    for nome in colunas_de_features:
        if "_lag" in nome:
            k = int(nome.split("_lag")[1])
            assert k >= HORIZONTE, f"{nome} usa informação posterior ao
momento da previsão"
```

10. Métricas de avaliação

Métrica	Uso	Observação
MAE e **RMSE** (em incidência)	Erro pontual	RMSE penaliza mais os picos
Skill relativo = 1 − MAE do modelo / MAE do baseline	Ganho sobre o baseline	Valor positivo indica melhora
WIS ou **pinball loss**	Qualidade dos intervalos e quantis	Padrão em avaliação de previsões epidêmicas
Cobertura empírica (80% e 95%)	Calibração dos intervalos	Cobertura próxima do nominal
Erro no pico	Magnitude e semana do pico previsto	Foco em decisão de saúde pública
MAPE	Evitar	Instável quando há poucos casos

11. Armadilhas e vieses

- **Notificação não é incidência real:** subnotificação, variação de testagem e mudanças de protocolo e de definição de caso alteram a série ao longo dos anos.
- **Atraso de notificação:** semanas recentes aparecem artificialmente baixas e são revisadas depois.
- **Poucos anos epidêmicos:** o modelo vê poucos picos; cuidado com sobreajuste e com conclusões fortes.
- **Falácia ecológica e medida de clima:** a estação meteorológica pode estar distante e não representar o município.
- **Fatores não medidos:** imunidade populacional, circulação de sorotipos (a sorotipagem costuma estar ausente na maior parte das notificações), vacinação e controle vetorial.

- **Período da pandemia de COVID-19:** alterou padrões de notificação e deve ser tratado explicitamente.
- **Vazamento sutil:** normalizar, imputar ou selecionar variáveis usando todo o conjunto.
- **Comparações múltiplas:** muitos municípios e modelos aumentam o risco de achados espúrios.
- **Dados revisados:** o mesmo ano pode ter versões diferentes; registre qual foi usada.

12. Ética, LGPD e uso responsável

- Os dados são anonimizados e públicos, mas **não tente reidentificar** ninguém e evite cruzamentos que criem células muito pequenas (municípios pequenos, faixas etárias detalhadas).
- Reporte resultados **agregados**; não publique registros individuais.
- Deixe claro que o projeto é **educacional e analítico**: não substitui a vigilância oficial nem deve orientar decisões clínicas.
- Cite as fontes e respeite os termos de uso de cada base.
- Seja honesto sobre limitações e sobre a incerteza das previsões.

13. Roteiro em fases

Fase	Entrega	Critério de aceite
0 – Fundação	Repositório, ambiente travado, CI, plano de análise, contratos de dados	`make test` passa; plano versionado antes de qualquer modelo
1 – Ingestão e qualidade	Pipeline de SINAN, INMET e IBGE; funil de exclusão	Contagens conferem com o TABNET dentro de tolerância documentada
2 – Exploração	Séries, mapas, sazonalidade, atraso de notificação	Relatório exploratório com limitações dos dados
3 – Baselines e validação	Baselines e rolling-origin funcionando	Teste anti-vazamento verde; métricas reproduzíveis
4 – Modelos	GLM e gradient boosting com intervalos	Ganho (ou ausência de ganho) reportado com IC e cobertura
5 – Interpretação e robustez	Resíduos, SHAP, defasagens, sensibilidade, análise espacial	Conclusões coerentes com a evidência; limitações explícitas

Fase	Entrega	Critério de aceite
6 – Comunicação	Relatório final e README	Qualquer pessoa reproduz os resultados com um comando

14. Rubrica de avaliação

Critério	Insuficiente	Esperado	Excelente
Pergunta e hipóteses	Vagas	Claras e mensuráveis	Pré-registradas com critério de decisão
Qualidade de dados	Limpeza sem registro	Funil de exclusão documentado	Contratos automatizados e conferência com fonte oficial
Validação	Split aleatório	Rolling-origin	Rolling-origin, teste final único e teste anti-vazamento
Modelagem	Apenas um modelo	Baselines e modelos comparados	Intervalos calibrados e análise por região
Interpretação	Só métricas	Importância e resíduos	Robustez, vieses e limitações discutidos
Reprodutibilidade	Notebooks soltos	Ambiente travado	Pipeline em um comando, dados versionados, CI
Comunicação	Apenas código	Relatório claro	Relatório com incerteza, ética e conclusões proporcionais

15. Projetos alternativos (saúde e biologia)

Projeto	Dados abertos	Ferramentas	Foco didático
Expressão gênica diferencial em câncer	TCGA (GDC) ou GEO	`pydeseq2`, `scanpy`, `statsmodels`	Alta dimensionalidade, correção para múltiplos testes
Risco de doença cardíaca	UCI Heart Disease	`scikit-learn`, `shap`	Calibração, justiça entre subgrupos, vazamento

Projeto	Dados abertos	Ferramentas	Foco didático
Internações evitáveis no SUS	SIH e CNES via PySUS	`pandas`, `geopandas`, `statsmodels`	Desigualdade regional, modelos de contagem
Microbioma e saúde	Human Microbiome Project	`scikit-bio`, `scikit-learn`	Dados composicionais

16. Referências

- Dicionário de dados do SINAN – Dengue (Portal Sinan / DATASUS) e documentação da plataforma de dados abertos do DATASUS.
- Documentação do **PySUS** (acesso programático aos sistemas do DATASUS).
- Hyndman, R. e Athanasopoulos, G. — *Forecasting: Principles and Practice* (livro aberto).
- Bracher, J. et al. (2021) — "Evaluating epidemic forecasts in an interval format", *PLOS Computational Biology* (WIS).
- Gneiting, T. e Raftery, A. (2007) — "Strictly Proper Scoring Rules, Prediction, and Estimation".
- Gasparrini, A. et al. (2010) — modelos de defasagem distribuída não lineares (DLNM).
- Kapoor, S. e Narayanan, A. (2023) — "Leakage and the reproducibility crisis in machine-learning-based science", *Patterns*.
- Projeto InfoDengue (Fiocruz/FGV) e iniciativas brasileiras de previsão de dengue, como o Mosqlimate.
- *The Turing Way* — guia de pesquisa reprodutível.

17. Próximo passo

Escolher a **unidade de análise piloto** (uma UF ou uma capital), o **horizonte de previsão** (por exemplo, 4 semanas) e o **intervalo de anos**, e iniciar a **Fase 0**: repositório, ambiente travado, contratos de dados e o plano de análise escrito antes de qualquer modelo.